

Product Requirements Document (PRD)

Aplikasi Prediksi Kualitas Red Wine Menggunakan Supervised Learning

1. Informasi Proyek

Nama Proyek

Wine Quality Classification App

Jenis Machine Learning

Supervised Learning - Classification

Framework Aplikasi

Streamlit

Dataset

Wine Quality Dataset (Red Wine)

2. Latar Belakang

Industri minuman anggur membutuhkan proses kontrol kualitas untuk memastikan produk yang dihasilkan memenuhi standar tertentu. Penilaian kualitas biasanya dilakukan oleh ahli (wine tester), namun proses tersebut membutuhkan waktu dan biaya.

Melalui pendekatan Machine Learning, kualitas wine dapat diprediksi berdasarkan karakteristik kimia yang dimiliki sehingga proses evaluasi menjadi lebih cepat dan efisien.

3. Tujuan Proyek

Membangun aplikasi berbasis web yang mampu memprediksi kualitas red wine berdasarkan parameter kimia menggunakan algoritma supervised learning.

Aplikasi dapat digunakan oleh pengguna untuk memasukkan nilai karakteristik wine dan memperoleh hasil prediksi kualitas secara otomatis.

4. Jenis Permasalahan

Classification

Dataset memiliki label berupa nilai kualitas (quality), sehingga tujuan model adalah mengklasifikasikan data ke dalam kelas kualitas tertentu.

Output yang dihasilkan berupa kategori kualitas wine.

5. Dataset

Dataset yang digunakan adalah **Wine Quality (Red Wine Dataset)**.

Dataset berisi data numerik hasil pengujian laboratorium terhadap sampel red wine.

Feature (X)

- fixed acidity
- volatile acidity
- citric acid
- residual sugar
- chlorides
- free sulfur dioxide
- total sulfur dioxide
- density
- pH
- sulphates
- alcohol

Seluruh fitur bertipe **numerik (continuous)**.

Target (y)

- quality

Variabel ini digunakan sebagai label klasifikasi.

Apabila diperlukan untuk meningkatkan performa model, nilai quality dapat diubah menjadi dua kelas:

- Good Wine (quality ≥ 7)

- Bad Wine (quality < 7)
-

6. Alasan Menggunakan Data Numerik

Seluruh atribut dalam dataset berupa nilai hasil pengukuran laboratorium sehingga tidak memerlukan proses NLP maupun encoding kategorikal.

Preprocessing yang dilakukan menjadi lebih sederhana, yaitu:

- pengecekan missing value
- pengecekan outlier
- standardisasi fitur
- train-test split

Pendekatan ini sesuai dengan karakteristik algoritma supervised learning berbasis data numerik.

7. Algoritma yang Digunakan

Logistic Regression

Logistic Regression digunakan sebagai model baseline karena:

- sederhana dan mudah diinterpretasikan
 - bekerja sangat baik pada data numerik
 - proses pelatihan cepat
 - menghasilkan probabilitas untuk setiap kelas
 - menjadi pembanding yang baik terhadap model ensemble
-

Random Forest

Random Forest dipilih karena:

- mampu menangkap hubungan non-linear antar fitur
- lebih tahan terhadap overfitting dibanding decision tree tunggal
- mampu menangani interaksi antar variabel dengan baik
- memiliki akurasi tinggi pada banyak dataset tabular
- dapat memberikan informasi feature importance

Alasan Menggunakan Dua Algoritma

Sesuai ketentuan tugas, minimal dua algoritma harus dibandingkan.

Perbandingan Logistic Regression dan Random Forest memungkinkan evaluasi antara model linear dan model ensemble sehingga pemilihan model terbaik dapat dilakukan berdasarkan hasil evaluasi seperti Accuracy, Precision, Recall, dan F1-Score.

8. Preprocessing

Tahapan preprocessing meliputi:

- pemeriksaan missing value
 - pemeriksaan duplicate data
 - deteksi outlier
 - feature scaling menggunakan StandardScaler
 - pembagian data training dan testing (80:20)
-

9. Evaluasi Model

Model akan dievaluasi menggunakan:

- Accuracy
- Precision
- Recall
- F1-Score
- Confusion Matrix

Model dengan performa terbaik akan dipilih untuk deployment.

10. Penyimpanan Model

Model terbaik akan disimpan menggunakan Joblib.

File yang disimpan meliputi:

- model.pkl
- scaler.pkl

Kedua file akan digunakan kembali pada proses inferensi di aplikasi.

11. Aplikasi

Aplikasi akan dibuat menggunakan **Streamlit**.

Fitur utama:

- input seluruh parameter kimia wine
 - tombol prediksi
 - hasil prediksi kualitas wine
 - probabilitas prediksi
 - tampilan sederhana dan interaktif
-

12. Alasan Menggunakan Streamlit

Streamlit dipilih karena:

1. Dibuat khusus untuk membangun aplikasi Data Science dan Machine Learning.
 2. Integrasi dengan Scikit-Learn sangat mudah sehingga model yang telah disimpan menggunakan Joblib dapat langsung digunakan.
 3. Tidak memerlukan pengetahuan HTML, CSS, maupun JavaScript.
 4. Proses deployment ke Streamlit Community Cloud sangat sederhana.
 5. Memiliki komponen input numerik (`number_input`, `slider`) yang sesuai dengan dataset wine yang seluruh fiturnya berupa data numerik.
 6. Antarmuka dapat dibuat hanya dengan beberapa baris kode sehingga pengembangan lebih cepat.
 7. Sangat cocok untuk demonstrasi model Machine Learning kepada pengguna non-teknis.
-

13. Deployment

Aplikasi akan dipublikasikan menggunakan Streamlit Community Cloud.

Repository GitHub akan berisi:

- app.py
 - model.pkl
 - scaler.pkl
 - notebook.ipynb
 - requirements.txt
 - README.md
-

14. Target Pengguna

- Mahasiswa pembelajar Machine Learning
 - Peneliti
 - Praktisi Data Science
 - Pengguna yang ingin mencoba prediksi kualitas wine berdasarkan karakteristik kimia
-

15. Kriteria Keberhasilan

Proyek dianggap berhasil apabila:

- model dapat melakukan prediksi dengan benar
- aplikasi berjalan tanpa error
- model dapat dimuat kembali dari file `.pkl`
- aplikasi dapat diakses secara publik
- seluruh alur supervised learning berjalan dari preprocessing hingga deployment